

# Práctica 3.

## Segmentación

Alberto Lardiés, 735976  
Devid Dokash, 780131

27 de abril de 2023

## Índice

<b>1. Segmentación de imágenes y la red neuronal U-Net</b>	<b>2</b>
<b>2. Resultados</b>	<b>2</b>
2.1. Red neuronal U-net . . . . .	3
2.2. Thresholding . . . . .	4

## 1. Segmentación de imágenes y la red neuronal U-Net

En esta práctica se ha visto la red neuronal convolucional U-net, una red neuronal utilizada para el principal objetivo de la práctica, la segmentación de imágenes.




Figura 1: Esquema de la red neuronal U-net.

No se entrará en extenso detalle sobre como se define esta red pero se usará su definición para explicar el siguiente paso en la memoria:

1. **Entrada:** se le pasa como entrada una imagen de un cerebro en escala de grises (luminosidades) como un tensor de sus píxeles.
2. **Capas convolucionales.** Estas capas se encargan de disminuir el tamaño de las imágenes para que sean menos costosas de procesar en pasos posteriores y las representan como estructuras (o mapas) de diferentes características (sea de bordes, texturas o formas) para reconocer posteriormente patrones más complejos y la segmentación en base a estos.
3. **Capas de concatenación.** Estas capas se encargan de unir en cada nivel la capa convolucional de la rama de codificación a la rama de decodificación. Utilizado para poder acceder a resultados y datos obtenidos en diferentes escalas de manera directa en los distintos niveles para las operaciones convenientes (sea recuperar la imagen original o ajustar el modelo para detectar patrones de segmentación más complejos).
4. **Capas convolucionales traspuestas.** Estas capas se encargan de recuperar la información original de la imagen y devolverá a su estado original, recuperando en cada nivel de convolución un nivel de detalle mayor para poder detectar los patrones más complejos y ajustar mejor el modelo.
5. **Capa de convolución de salida.** La capa final de la red, con el modelo ya ajustado, identificará la probabilidad de que un píxel sea de cada clase, seleccionando la clase con mayor probabilidad y finalmente, consiguiendo la segmentación de las imágenes.

## 2. Resultados

En este apartado se profundiza en los resultados de la arquitectura U-net, evaluados mediante la métrica Dice Similarity Coefficient y comparados con un algoritmo tradicional, el thresholding. A continuación las tanda de muestras utilizadas para la evaluación:

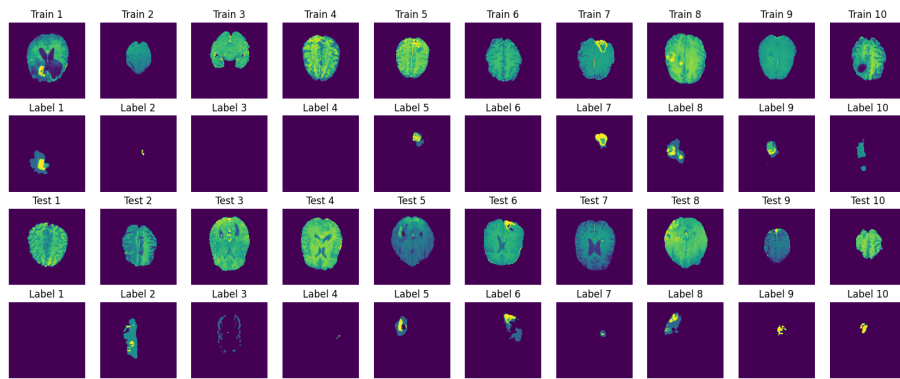


Figura 2: Esquema de la red neuronal U-net.

## 2.1. Red neuronal U-net

Se puede observar como la red neuronal obtiene resultados bastante buenos, aunque en algunas de las muestras pueda fallar más o menos y la segmentación difiera ligeramente de las segmentaciones originales.

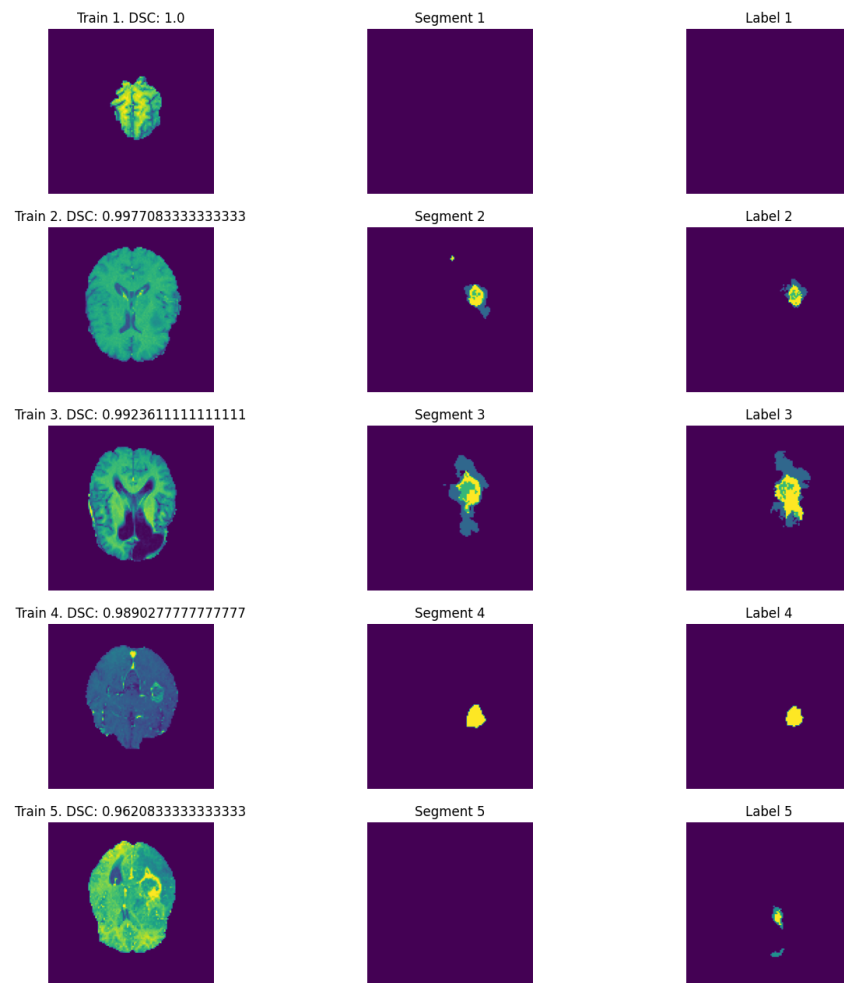


Figura 3: Esquema de la red neuronal U-net.

Podría haber varias razones por las cuáles la red no es del todo precisa, sea la diferencia de los datos, las inconsistencia de los mismos o que la arquitectura no es adecuada para este problema, pero no se sabría realmente el porque.

## 2.2. Thresholding

Se ha seleccionado como algoritmo de comparación el thresholding por su sencillez. La principal diferencia del thresholding es la manera que determina la segmentación de las imágenes.

Mientras la red neuronal trata las imágenes y detecta patrones para ajustar al modelo, el thresholding ignora totalmente las características de las imágenes y de sus atributos y depende totalmente de la intensidad de las muestras.

En otras palabras, mientras que la red neuronal se basa en las características de sus muestras para encontrar patrones y relaciones que identifiquen las diferentes segmentaciones de la imagen, un algoritmo tradicional como el thresholding se basa en la intensidad de los píxeles, ignorando totalmente la relación entre los mismos o los patrones que pudiese haber.

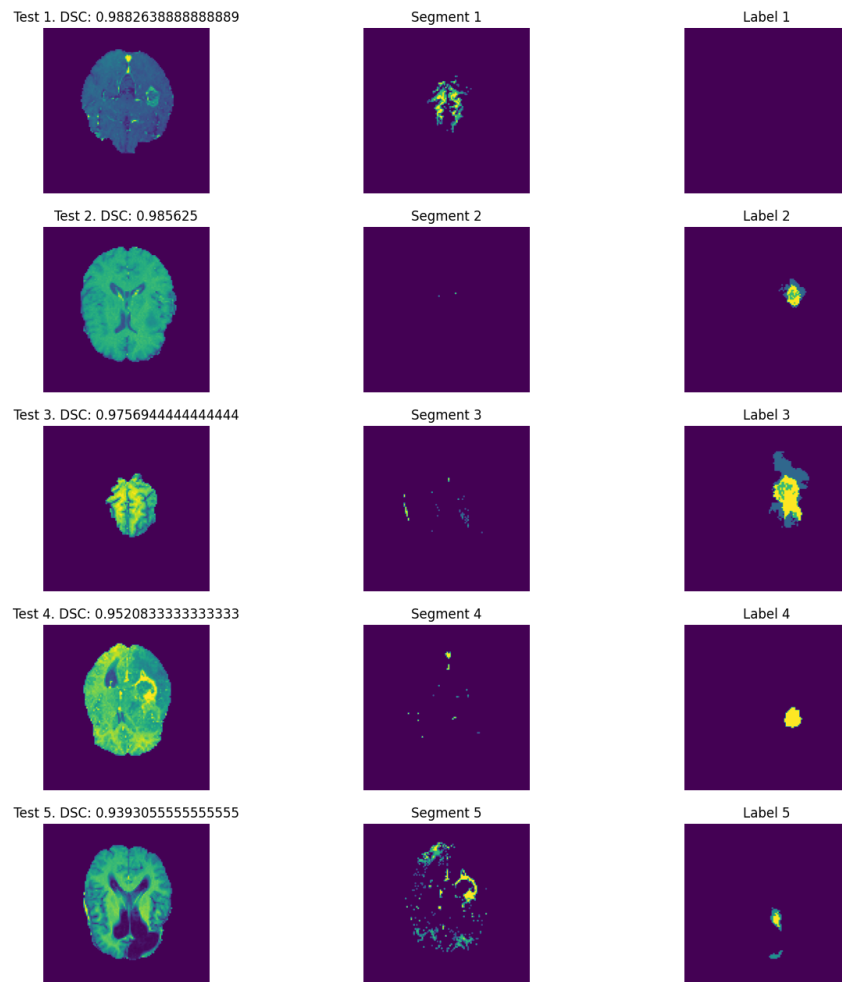


Figura 4: Esquema de la red neuronal U-net.